Instituto Superior de Engenharia
Politécnico de Coimbra

Conhecimento e Raciocínio

Licenciatura em Engenharia Informática: 2º ano - 2º semestre
2025/2026

TRABALHO PRÁTICO

1. Objetivos

Pretende-se que os alunos explorem e aprofundem os conceitos de raciocínio baseado em casos, tratamento de datasets e de redes neuronais feedforward.
O trabalho deve ser implementado usando o Matlab, podendo apenas usar a toolbox Deep Learning (redes neuronais).

2. Descrição do dataset

O dataset fornecido no ficheiro **dataset_TP.csv** contem 5000 registos de sobre o diagnóstico de falhas num motor industrial. O dataset tem valores em falta em alguns atributos, nomeadamente na classe target.

Analisando os 14 atributos de entrada, foi registada na última coluna o tipo de falha diagnosticada:

- Normal (Funcionamento normal)
- Eletrical Failure (Falha elétrica)
- Mechanical Failure (Falha mecânica)

Os atributos de entrada são:

- Atributos numéricos:

Atributo	Descrição
temperature	Temperatura medida no equipamento (°C), indica o estado térmico do sistema. Valores elevados podem sinalizar sobreaquecimento.
vibration	Nível de vibração do equipamento (unidades arbitrárias), usado para detectar falhas mecânicas ou desequilíbrios.
rotation_speed	Velocidade de rotação do motor ou eixo principal (RPM), mostra se o equipamento está a operar dentro do regime normal.
voltage	Tensão elétrica aplicada ao sistema (V), fundamental para monitorizar a alimentação e possíveis falhas elétricas.
current	Corrente elétrica consumida pelo equipamento (A), indica sobrecarga ou falha elétrica.
pressure	Pressão interna ou do fluido do sistema (bar ou Pa), útil para identificar falhas hidráulicas ou mecânicas.
noise_level	Nível de ruído gerado pelo equipamento (dB), alterações súbitas podem indicar falha mecânica.
efficiency	Eficiência operacional do sistema (0–1), representa quão bem a energia é convertida em trabalho útil.
load_val	Carga aplicada ao equipamento (% ou unidades relativas_
torque	Torque gerado pelo motor ou eixo principal (Nm), usado para avaliar esforço mecânico e identificar problemas de resistência ou sobrecarga.

- Atributos categóricos:

Atributo	Descrição	Valores possíveis
maintenance_level	Nível de manutenção do equipamento, indica se foi realizada manutenção preventiva ou corretiva.	Low (Baixo), Medium (Médio), High (Alto)
operating_mode	Modo de operação do equipamento, ajuda a contextualizar os dados de sensores.	Idle (Parado), Normal (Normal), Overload (Sobrecarga)
cooling_type	Tipo de arrefecimento usado no equipamento, pode afetar temperatura e eficiência.	Air (Ar), Oil (Óleo)
sensor_status	Estado do sensor que recolheu os dados, indicando se está a funcionar corretamente ou apresenta aviso de falha.	OK (Funcional), Warning (Aviso)

3. Tarefas a realizar

3.1 Tratamento do dataset

Conversão de atributos categóricos para numéricos

- Propor uma forma de conversão que mantenha as relações dadas pelos valores

Preenchimento de valores em falta (missing values)

- Nos atributos de entrada:
  - Pode usar **média, mediana ou moda**, conforme achar mais adequado. Justifique as opções.
- No target:
  - Deve aplicar **CBR (Retrieve)** da seguinte forma: procurar o registo mais similar com *target* conhecido e copiar a classe para o *missing value*.
  - Justificar os pesos dados a cada atributo.

Notas importantes:

- Não pode remover linhas com *missing values*.
- Não pode simplesmente substituir *missing* no target por valores aleatórios
- Não pode transformar todos os categóricos em números arbitrários sem justificação (ex.: Low=1, Medium=2, High=3) sem discutir a implicação da ordenação.
- Esta tarefa deve ser implementada em Matlab e não pode usar outras ferramentas (Excel, por exemplo)

3.2 Raciocínio baseado em casos

a) Implementar um sistema de CBR:

1. **Retrieve**: calcular as distâncias locais e a similaridade global para um novo caso e mostrar os casos acima de um limiar.
2. **Reuse**: use uma rede neuronal *feedforward* para propor um valor ajustado do atributo *temperature*, usando como variáveis de entrada os atributos *vibration*, *rotation_speed* e *voltage*
3. **Revise**: Perguntar ao utilizador se pretende alterar a temperatura com o valor dado pela RN
4. **Retain**: Acrescentar o novo caso ao dataset, caso se justifique.

Nota: Deve implementar o sistema CBR em Matlab e não pode usar bibliotecas externas de CBR ou usar classificadores prontos como substituto do CBR.

b) Testar o sistema de CBR:

1. Utilize os casos do ficheiro ***dataset_TP_test.csv*** para testar o sistema de CBR
2. Analise diferentes pesos para os atributos
3. Compare as respostas do sistema usando o dataset normalizado *versus* o dataset não normalizado (a coluna de target não deve ser normalizada)
4. Para cada configuração testada deve registar a % de casos que o sistema CBR deu como resposta o caso com a maior similiaridade que é coincidente à resposta correta (última coluna do ficheiro ***dataset_TP_test.csv***)

3.3 Redes neuronais feedforward

a) Implementar e testar redes neuronais

Usar o *dataset* já tratado em 3.1 para estudar, treinar e analisar redes neuronais *feedforward* para a tarefa de classificação de falhas.

Implemente uma função em Matlab que:

i. Construa a matriz de entrada a partir dos atributos de entrada
ii. Construa o target binário (uma linha para cada classe) a partir da coluna de target.
iii. Usando as funções da Toolbox Deep Learning do Matlab, treine e teste diferentes redes neuronais *feedforward*, mudando:
   - Topologia: *default*, aumentar número de camadas e de neurónios
   - Diferentes funções de treino: traingd, trainbr, traingd, trainscg
   - Diferentes funções de ativação na camada de saída: purelin, tansig, logsig, softmax
   - Diferentes proporções para aa divisão do dataset em treino/validação/teste
   - Pode também testar diferentes coeficientes de aprendizagem, nº de épocas, e outros parâmetros que ache relevantes

Deve executar **10 repetições de cada configuração** e registar **<u>as médias</u>** das precisões de acerto global e de teste.

b) Usando as 3 melhores e as 3 piores configurações encontradas no estudo anterior, repita as experiências e compare o desempenho dessas configurações usando o dataset normalizado versus não normalizado. Analise e guarde os *plotconfusion* que permitam justificar as conclusões e que sejam relevantes incluir no relatório.

c) Grave as **três** redes neuronais com melhores desempenhos.

NOTA: sugere-se a adaptação do ficheiro Excel dado nas aulas práticas, para registar resultados de taxa de acerto global e taxa de acerto de teste das diferentes configurações e obter as conclusões.

d) Testar as melhores redes

Use as três melhores redes gravadas em a) para classificar os registos do ficheiro **dataset_TP_test.csv** e analisar a sua taxa de acerto de acerto em cada classe. Analise e guarde os *plotconfusion* que permitam justificar as conclusões e que sejam relevantes incluir no relatório

3.4 CBR vs Redes Neuronais

Faça um estudo comparativo das duas abordagens implementadas. Analise e compare os resultados e as diferenças entre os métodos. Discuta as respetivas vantagens e limitações de cada método.

3.5 Escrita do Relatório

No moodle encontra-se um template do relatório que pode usar e adaptar ao seu estilo.

Deve explicar detalhadamente as tarefas implementadas, mostrar tabelas e gráficos resumo dos valores obtidos em cada etapa do trabalho. Nas redes neuronais deve mostrar também os *plot confusion* que permitam justificar as conclusões alcançadas. Pode usar o ficheiro *excel* como anexo de todos os resultados obtidos, mas os resultados principais e as conclusões mais relevantes devem ser registadas e justificadas no relatório. O limite máximo de páginas do relatório: 20 páginas (excluindo capa e índice).

4. Regras para a realização do trabalho

- Os grupos de trabalho são de dois alunos. Apenas serão aceites trabalhos individuais após uma justificação válida que deve ser apresentada ao docente das aulas práticas.

- A **data única** de **entrega** do trabalho é até às 23.59 do dia **10 de maio de 2026**.

- Ficheiro a submeter no Moodle:
  - Deve ser em formato ZIP
  - Nome do ficheiro: deve ter os nomes, números, e turma dos alunos dos elementos do grupo (ex: **AnaMelo222222_P1_PedroCosta33333_P3.ZIP)**
  - Deve conter: código Matlab de todas as tarefas implementadas, ficheiro Excel com os resultados globais recolhidos nas diferentes tarefas e PDF do relatório

- As defesas serão nas aulas das semanas **11 a 22 de maio.**

- Para a defesa, cada grupo terá de fazer a inscrição de um (**só 1**) dos seus elementos no Moodle na turma que frequentam e onde fizeram a submissão do trabalho.
  Os *slots* para inscrição nas defesas serão disponibilizados no dia da submissão do trabalho.

- A defesa do trabalho é **obrigatória** e com a presença de todos os membros do grupo. Não fazendo a defesa, o trabalho será cotado com zero valores.

- O trabalho prático tem a cotação de 8 valores (numa escala de 0 a 20).

- Cotações
  - Tarefa 3.1 Tratamento do dataset – 10%
  - Tarefa 3.2 CBR – implementação e teste – 20%
  - Tarefa 3.3 RN – implementação e teste – 20%
  - Tarefa 3.4 CBR vs RN – 10%
  - Relatório – 20%
  - Defesa – 20%

5. Utilização de Ferramentas de Inteligência Artificial

Os estudantes podem usar ferramentas de IA de **forma responsável e crítica**.
Não serão aceites trabalhos com código gerado por IA.
Não serão aceites trabalhos com relatórios gerados por IA.

Durante a defesa os alunos terão de ser capazes de:
Explicar detalhadamente o código implementado
Alterar o código implementado de acordo com o que lhes for solicitado
Implementar novas funções semelhantes às realizadas neste trabalho

No caso de uma defesa em que estas tarefas não sejam minimamente cumpridas **o trabalho será anulado**.